# UNIVERSIDAD TECNOLÓGICA DEL VALLE DE TOLUCA

**Dirección de Carrera de Tecnologías de la Información y Comunicación**

**Ingeniería en Desarrollo y Gestión de Software**

**PRACTICA**

**ESTUDIANTE:** Jaime Díaz González

**GRUPO:** IDGS-92

**CUATRIMESTRE:** 9

**LUGAR**

Santa María Atarasquillo, Lerma, México

**FECHA DE ENTREGA**

02 DE Junio del 2026

# Contenido

Parte I. Análisis teórico ..... 3
Actividad 1. Tipos y fuentes de datos ..... 3
Actividad 2. Modelado de Data Warehouse ..... 5
Actividad 3. Técnicas de Limpieza de Datos ..... 10
Actividad 4. Minería de Datos ..... 15
Parte II. Desarrollo Práctico ..... 18
Parte III. Minería de Datos ..... 19
Actividad 6. Análisis Exploratorio ..... 19
Actividad 7. Predicción Simple ..... 20

# Parte I. Análisis teórico

## Actividad 1. Tipos y fuentes de datos

En esta práctica se analizan diferentes fuentes de información que se pueden encontrar en un sistema de análisis de datos. Cada archivo contiene información con una estructura distinta, por lo que es importante identificar correctamente su tipo para poder procesarlo de manera adecuada. En este caso se revisan cuatro fuentes: ventas.csv, clientes.json, comentarios.txt y productos.xlsx.

1. **Clasificación de cada fuente de datos**

   ventas.csv
   Lo clasifiqué como dato estructurado. Por lo que entiendo del formato CSV, la información se organiza en filas y columnas de manera ordenada. Cada venta es un registro y cada columna guarda un dato específico como fecha, producto, cantidad o total. Al ser un formato tabular, es fácil de leer y procesar con herramientas de análisis.

   clientes.json
   Este lo consideré dato semiestructurado. El formato JSON permite organizar la información con etiquetas y valores, lo cual le da cierto orden, pero no es una tabla rígida como un CSV o un Excel. Puede que algunos clientes tengan más campos que otros o que la información varíe en estructura de un registro a otro. Por eso no es completamente estructurado ni totalmente libre.

   comentarios.txt
   Lo identifiqué como dato no estructurado. Es un archivo de texto sin formato fijo, donde los clientes escriben opiniones, quejas o sugerencias de forma libre. No hay columnas ni organización predefinida, así que para poder analizarlo se necesitarían técnicas de procesamiento de texto.

   productos.xlsx
   Este archivo lo clasifiqué también como dato estructurado. Al ser una hoja de cálculo de Excel, la información se guarda de forma ordenada en filas y columnas. Cada columna representa un atributo del producto, como código, nombre, categoría o precio. Esa organización clara hace que sea fácil de entender y procesar directamente.

## 2. Justificar respuesta

Los datos estructurados están ordenados en tablas con filas y columnas fijas, lo que los hace fáciles de leer y analizar. Los semiestructurados tienen cierto orden pero sin una estructura tan rígida; pueden tener etiquetas o jerarquías y los registros no siempre son iguales. Los no estructurados no siguen ningún formato definido y necesitan procesarse antes de analizarlos.

Ventas y productos como estructurados, porque su información está organizada en columnas y filas claras.

Clientes como semiestructurado, porque usa llaves y objetos, pero los datos pueden variar entre registros.

Comentarios como no estructurado, ya que contiene texto libre sin ninguna organización tabular.

## 3. Ventajas y desventajas de cada tipo de dato

Datos estructurados
La ventaja es que son muy fáciles de guardar, consultar y analizar con herramientas como SQL, Excel o Pandas. Se pueden hacer filtros, cálculos y búsquedas rápido. La desventaja es que son poco flexibles, porque si quiero agregar algo nuevo a veces hay que cambiar toda la estructura, y no sirven para texto libre o información compleja.

Datos semiestructurados
Lo bueno es que son más flexibles que los estructurados. Puedo tener registros con distintos campos y se adaptan mejor cuando los datos cambian. Lo malo es que analizarlos cuesta más trabajo, porque hay que entender su estructura jerárquica antes de procesarlos, y no siempre se integran fácil con bases de datos tradicionales.

Datos no estructurados
Su ventaja es que guardan información muy variada y real, como opiniones, imágenes o audios, que reflejan mejor lo que la gente genera en el día a día. La desventaja es que son los más difíciles de analizar, porque primero necesitan limpieza y procesamiento especializado, además no se pueden consultar directamente como una tabla.

## Actividad 2. Modelado de Data Warehouse

Después de clasificar los archivos por su tipo de dato ahora vamos a aprovechar esa información para el análisis de la empresa. Como tenemos datos de ventas, clientes, productos y comentarios, cada uno con su propio formato, diseñamos el data warehouse para centralizar la información.

### 1. Diagrama Modelo Estrella

La tabla principal es VENTAS que es donde guardamos lo más importante del negocio: cuánto se vendió, qué cantidades y los montos totales. Es decir lo que después vamos a querer analizar.

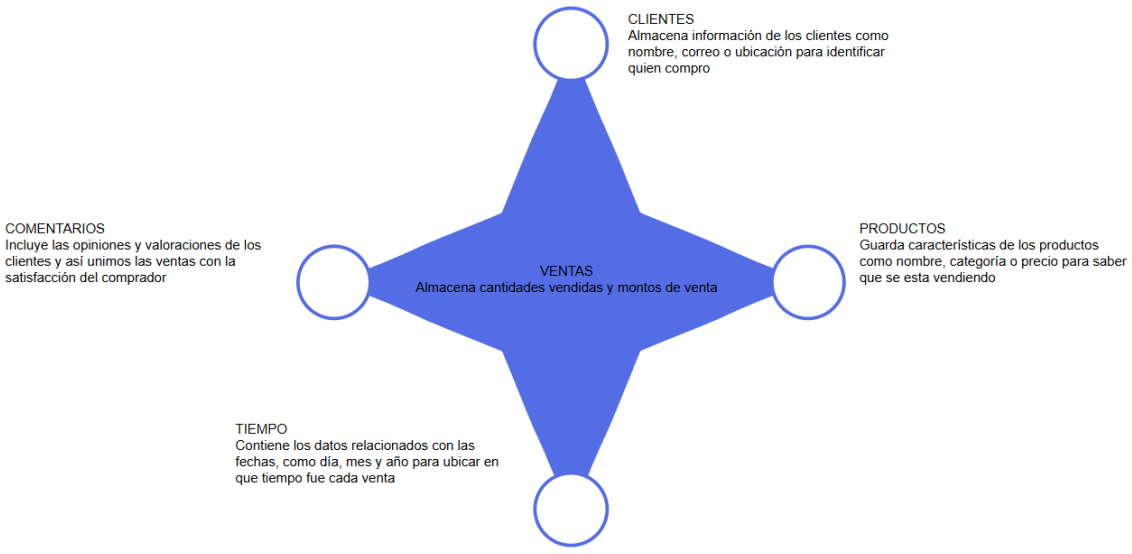
Alrededor están las otras tablas, que nos sirven para darle contexto a esas ventas y poder verlas desde diferentes ángulos:

TIEMPO para saber cuándo se vendió.

PRODUCTOS para ver qué se vendió.

CLIENTES para conocer a quién se le vendió.

COMENTARIOS para revisar qué opinaron los clientes.



## 2. Diagrama Modelo Copo de Nieve

Aquí las tablas se normalizan o sea se dividen en tablas más chiquitas para no repetir información.

En nuestro caso, algunas dimensiones se partieron para evitar redundancia. Por ejemplo, en vez de guardar la ciudad una y otra vez en cada registro de cliente, se crea una tabla aparte llamada CIUDAD.

VENTAS: es la tabla principal, aquí se guardan las ventas con sus cantidades y montos.

CLIENTE: tiene los datos básicos de los clientes, como su nombre o correo.

CIUDAD: la separamos de cliente para no andar repitiendo la ciudad en cada registro. Solo guarda el nombre de la ciudad.

ESTADO: guarda los estados o provincias asociados a cada ciudad. Facilita análisis regionales de ventas.

PAIS: contiene los países donde se encuentran los clientes. Es el nivel geográfico más alto dentro de la dimensión de ubicación.

PRODUCTO: aquí va la info de los productos, como nombre y precio, pero la categoría la dejamos en otra tabla.

CATEGORIA: la creamos para guardar las categorías aparte y no estarlas repitiendo en cada producto.

DEPARTAMENTO: representa agrupaciones generales de categorías. Por ejemplo, las categorías Lácteos y Carnes pueden pertenecer al departamento de Alimentos.

MARCA: contiene las marcas comerciales asociadas a los productos. Esto permite analizar ventas por fabricante o proveedor.

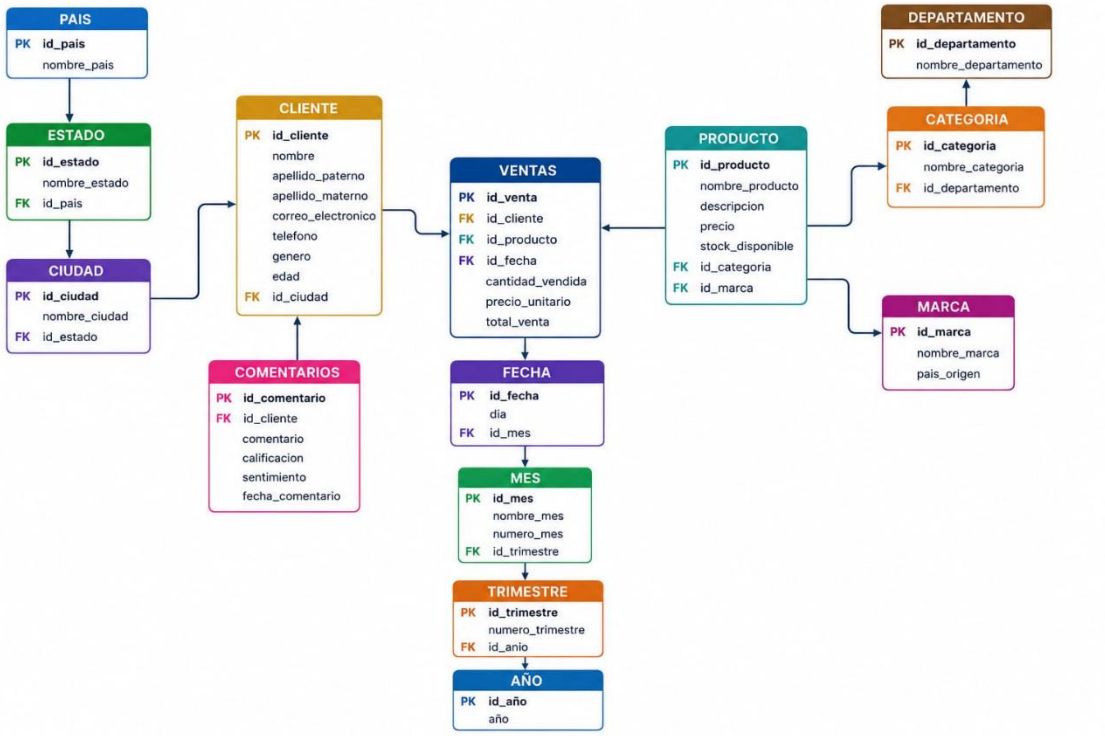
COMENTARIOS: aquí se guardan las opiniones y valoraciones que dejan los clientes.

FECHA: tiene los datos de la fecha en que se hizo cada venta.

MES: la separamos de tiempo para no repetir el mes en todos lados. Guarda el nombre del mes y el año.

TRIMESTRE: permite realizar análisis por periodos trimestrales.

AÑO: contiene los años registrados en el sistema para realizar análisis históricos.



## 3. Comparación entre el Modelo Estrella y el Modelo Copo de Nieve

El Modelo Estrella es el más simple y fácil de armar ya que todas las tablas se conectan directo a la tabla principal, entonces hacer consultas es rápido y sin tanta complicación. Por eso se usa cuando lo que importa es el rendimiento.

El Modelo Copo de Nieve ya es más complejo porque normaliza las tablas, o sea, las parte en tablas más pequeñas. Esto hace que haya más relaciones entre tablas, pero a cambio no se repiten tanto los datos y se ahorra espacio de almacenamiento.

El Modelo Estrella va más por el lado de la velocidad y la sencillez, mientras que el Copo de Nieve se enfoca en tener todo más organizado y sin redundancia.

Por eso, al hacer consultas, el Estrella suele ser más rápido porque tiene menos uniones entre tablas. En cambio, el Copo de Nieve puede necesitar más JOINs por todas las tablas adicionales que se generan.

## 4. Ventajas y desventajas

### Modelo Estrella

Ventajas:

- Es fácil de diseñar y cualquiera le entiende rápido.
- Las consultas son más rápidas porque todo está conectado directo a la tabla de hechos.
- Tiene poquitas relaciones entre tablas, entonces no hay que estar haciendo tantos JOINs.
- Es muy práctico para hacer reportes y dashboards sin complicarse.
- Funciona súper bien con herramientas de Business Intelligence.

Desventajas:

- Se puede repetir mucha información, por ejemplo la misma ciudad en varios registros de clientes.
- Al haber redundancia, consume más espacio de almacenamiento.
- Tiene un nivel bajo de normalización, lo que puede meter problemas si los datos no se cuidan bien.

- Si alguien actualiza un dato en un solo lugar pero no en los demás, se pueden generar inconsistencias.

**Modelo Copo de Nieve**

Ventajas:

- Reduce bastante la redundancia porque las dimensiones se normalizan y se dividen en tablas más chicas.
- La información queda mejor organizada, cada cosa en su tabla correspondiente.
- Hay mayor integridad y consistencia de los datos, así es más difícil que haya errores.
- Ocupa menos espacio de almacenamiento al no repetir datos.
- Es más fácil dar mantenimiento cuando las tablas son complejas.

Desventajas:

- El diseño ya no es tan sencillo, hay que pensar bien cómo dividir las tablas.
- Hay más tablas y más relaciones, entonces el diagrama se vuelve más complejo.
- Las consultas son más lentas porque toca hacer más JOINs para juntar la información.
- Para alguien que apenas va empezando, puede ser más difícil de entender a la primera.

# Actividad 3. Técnicas de Limpieza de Datos

## Técnicas básicas de limpieza de datos

### 1. Eliminación de duplicados

La eliminación de duplicados consiste en identificar y eliminar registros repetidos dentro de una base de datos. Los duplicados suelen generarse por errores de captura, fallas en procesos de integración o registros ingresados más de una vez.
La presencia de datos duplicados puede provocar análisis incorrectos, ya que algunos valores se contabilizan varias veces.

**ANTES DE ELIMINAR DUPLICADOS**

| id_cliente | nombre | correo | teléfono | ciudad |
|---|---|---|---|---|
| 1 | Juan Pérez | juan@gmail.com | 5512345678 | Ciudad de México |
| 2 | María López | maria@gmail.com | 5587654321 | Guadalajara |
| 3 | Juan Pérez | juan@gmail.com | 5512345678 | Ciudad de México |
| 4 | Carlos Ramírez | carlos@gmail.com | 5534567890 | Monterrey |
| 5 | Ana Torres | ana@gmail.com | 5598765432 | Puebla |

**DESPUÉS DE ELIMINAR DUPLICADOS**

| id_cliente | nombre | correo | teléfono | ciudad |
|---|---|---|---|---|
| 1 | Juan Pérez | juan@gmail.com | 5512345678 | Ciudad de México |
| 2 | María López | maria@gmail.com | 5587654321 | Guadalajara |
| 4 | Carlos Ramírez | carlos@gmail.com | 5534567890 | Monterrey |
| 5 | Ana Torres | ana@gmail.com | 5598765432 | Puebla |

### 2. Tratamiento de valores nulos

Los valores nulos representan información faltante o desconocida dentro de un conjunto de datos. Estos pueden afectar el análisis y provocar errores en algoritmos de procesamiento.

Existen diferentes formas de tratarlos:

- Eliminar registros con datos faltantes.
- Reemplazar los valores nulos por la media.
- Reemplazar por la mediana.
- Reemplazar por la moda.

**ANTES DEL TRATAMIENTO DE VALORES NULOS**

| id_venta | id_cliente | id_producto | id_fecha | cantidad_vendida | precio_unitario | total_venta |
|---|---|---|---|---|---|---|
| 1 | 101 | 501 | 2024-05-01 | 2 | 25.50 | 51.00 |
| 2 | 102 | 502 | 2024-05-01 | NULL | 15.00 | NULL |
| 3 | 103 | 503 | 2024-05-02 | 1 | NULL | 30.00 |
| 4 | 104 | 504 | 2024-05-02 | 3 | 12.00 | 36.00 |
| 5 | 105 | 505 | 2024-05-03 | NULL | 20.00 | 40.00 |
| 6 | 106 | 506 | 2024-05-03 | 4 | NULL | 52.00 |

**DESPUÉS DEL TRATAMIENTO DE VALORES NULOS (REEMPLAZADOS POR LA MEDIA)**

| id_venta | id_cliente | id_producto | id_fecha | cantidad_vendida | precio_unitario | total_venta |
|---|---|---|---|---|---|---|
| 1 | 101 | 501 | 2024-05-01 | 2 | 25.50 | 51.00 |
| 2 | 102 | 502 | 2024-05-01 | 2.50 | 15.00 | 41.80 |
| 3 | 103 | 503 | 2024-05-02 | 1 | 18.50 | 30.00 |
| 4 | 104 | 504 | 2024-05-02 | 3 | 12.00 | 36.00 |
| 5 | 105 | 505 | 2024-05-03 | 2.50 | 20.00 | 40.00 |
| 6 | 106 | 506 | 2024-05-03 | 4 | 18.50 | 52.00 |

## 3. Corrección de formatos

Esta técnica consiste en unificar la forma en que se representan los datos dentro de una base de información.
Es común encontrar diferentes formatos para fechas, teléfonos, monedas o identificadores.

**ANTES DE LA CORRECCIÓN DE FORMATOS**

| id_venta | id_cliente | id_producto | fecha_venta | cantidad_vendida | precio_unitario | total_venta |
|---|---|---|---|---|---|---|
| 1 | 101 | 501 | 01/05/2024 | 2 | 25.50 | 51.00 |
| 2 | 102 | 502 | 2024-05-01 | 1 | 15.00 | 15.00 |
| 3 | 103 | 503 | 1 May 2024 | 3 | 12.00 | 36.00 |
| 4 | 104 | 504 | 05/02/2024 | 4 | 20.00 | 80.00 |
| 5 | 105 | 505 | 2024/05/03 | 2 | 18.00 | 36.00 |
| 6 | 106 | 506 | 03-05-2024 | 5 | 10.00 | 50.00 |

**DESPUÉS DE LA CORRECCIÓN DE FORMATOS**

| id_venta | id_cliente | id_producto | fecha_venta | cantidad_vendida | precio_unitario | total_venta |
|---|---|---|---|---|---|---|
| 1 | 101 | 501 | 2024-05-01 | 2 | 25.50 | 51.00 |
| 2 | 102 | 502 | 2024-05-01 | 1 | 15.00 | 15.00 |
| 3 | 103 | 503 | 2024-05-01 | 3 | 12.00 | 36.00 |
| 4 | 104 | 504 | 2024-05-02 | 4 | 20.00 | 80.00 |
| 5 | 105 | 505 | 2024-05-03 | 2 | 18.00 | 36.00 |
| 6 | 106 | 506 | 2024-05-03 | 5 | 10.00 | 50.00 |

### 4. Estandarización

La estandarización consiste en unificar la forma en que se escriben o representan determinados valores.
Frecuentemente aparecen diferencias por mayúsculas, minúsculas, abreviaturas o errores de escritura.

**ANTES DE LA ESTANDARIZACIÓN**

| id_cliente | nombre | correo | ciudad | estado | país |
|---|---|---|---|---|---|
| 1 | Juan Pérez | juan.perez@gmail.com | México | CDMX | México |
| 2 | María López | maria.lopez@gmail.com | Mexico | CDMX | Mexico |
| 3 | Carlos Ramírez | carlos.ramirez@gmail.com | MéXICO | cdmx | México |
| 4 | Ana Torres | ana.torres@gmail.com | mexico | Ciudad de Mexico | México |
| 5 | Luis Sánchez | luis.sanchez@gmail.com | MÉX. | CD. MX. | MEXICO |
| 6 | Paula Gómez | paula.gomez@gmail.com | Méx. | CdMx | Méx. |

**DESPUÉS DE LA ESTANDARIZACIÓN**

| id_cliente | nombre | correo | ciudad | estado | país |
|---|---|---|---|---|---|
| 1 | Juan Pérez | juan.perez@gmail.com | Ciudad de México | Ciudad de México | México |
| 2 | María López | maria.lopez@gmail.com | Ciudad de México | Ciudad de México | México |
| 3 | Carlos Ramírez | carlos.ramirez@gmail.com | Ciudad de México | Ciudad de México | México |
| 4 | Ana Torres | ana.torres@gmail.com | Ciudad de México | Ciudad de México | México |
| 5 | Luis Sánchez | luis.sanchez@gmail.com | Ciudad de México | Ciudad de México | México |
| 6 | Paula Gómez | paula.gomez@gmail.com | Ciudad de México | Ciudad de México | México |

## Técnicas avanzadas de limpieza de datos

### 1. Detección de outliers

Los outliers o valores atípicos son registros que se encuentran muy alejados del comportamiento normal de los datos.
Estos valores pueden deberse a errores de captura, fallas de sensores o situaciones extraordinarias.

**ANTES: Datos con posible outlier**

| Fecha | Ventas diarias (MXN) |
|---|---|
| 2024-05-01 | 100 |
| 2024-05-02 | 120 |
| 2024-05-03 | 150 |
| 2024-05-04 | 130 |
| 2024-05-05 | 110 |
| 2024-05-06 | 140 |
| 2024-05-07 | 115 |
| 2024-05-08 | 125 |
| 2024-05-09 | 135 |
| 2024-05-10 | 5,000 |

OUTLIER
(valor atípico)

## 2. Imputación estadística

La imputación estadística es una técnica utilizada para reemplazar datos faltantes utilizando cálculos matemáticos o modelos predictivos.
A diferencia del tratamiento básico de nulos, esta técnica busca estimar valores de manera más precisa.

**IMPUTACIÓN ESTADÍSTICA (USANDO LA MODA)**

**ANTES DE LA IMPUTACIÓN (DATOS FALTANTES)**

| id_venta | fecha | producto | categoría | cantidad | precio_unitario ($) | monto_total ($) | método_pago | sucursal |
|---|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | Electrónica | 2 | 15,000 | 30,000 | Tarjeta | Centro |
| 2 | 01/05/2024 | Mouse | Accesorios | N/A | 250 | N/A | Efectivo | Norte |
| 3 | 02/05/2024 | Teclado | Accesorios | 1 | 450 | 450 | Tarjeta | N/A |
| 4 | 02/05/2024 | Monitor | Electrónica | N/A | 3,200 | N/A | Transferencia | Centro |
| 5 | 03/05/2024 | Impresora | Oficina | 1 | 2,100 | 2,100 | Efectivo | Sur |

**DESPUÉS DE LA IMPUTACIÓN (DATOS COMPLETOS)**

| id_venta | fecha | producto | categoría | cantidad | precio_unitario ($) | monto_total ($) | método_pago | sucursal |
|---|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | Electrónica | 2 | 15,000 | 30,000 | Tarjeta | Centro |
| 2 | 01/05/2024 | Mouse | Accesorios | 1 | 250 | 2,100 | Efectivo | Norte |
| 3 | 02/05/2024 | Teclado | Accesorios | 1 | 450 | 450 | Tarjeta | Centro |
| 4 | 02/05/2024 | Monitor | Electrónica | 1 | 3,200 | 2,100 | Transferencia | Centro |
| 5 | 03/05/2024 | Impresora | Oficina | 1 | 2,100 | 2,100 | Efectivo | Sur |

## 3. Validación cruzada

La validación cruzada es una técnica utilizada para verificar la calidad y consistencia de los datos mediante comparaciones entre diferentes fuentes o particiones de información.
Su objetivo es detectar errores, inconsistencias o registros incorrectos antes de realizar análisis avanzados.

**1. ANTES DE LA VALIDACIÓN CRUZADA (DATOS ORIGINALES)**

| id_venta | fecha | producto | cliente_id | cantidad | precio_unitario ($) | monto_total ($) | método_pago | sucursal |
|---|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | 101 | 2 | 15,000 | 30,000 | Tarjeta | Centro |
| 2 | 01/05/2024 | Mouse | 102 | 3 | 250 | 750 | Efectivo | Norte |
| 3 | 02/05/2024 | Teclado | 103 | 1 | 450 | 450 | Tarjeta | Centro |
| 4 | 02/05/2024 | Monitor | 104 | 1 | 3,200 | 3,200 | Transferencia | Centro |
| 5 | 03/05/2024 | Impresora | 105 | 2 | 2,100 | 5,000 | Efectivo | Sur |

3. DESPUÉS DE LA VALIDACIÓN CRUZADA (DATOS VALIDADOS)

| id_venta | fecha | producto | cliente_id | cantidad | precio_unitario ($) | monto_total ($) | método_pago | sucursal | estado_validación |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | 101 | 2 | 15,000 | 30,000 | Tarjeta | Centro | ✔ Válido |
| 2 | 01/05/2024 | Mouse | 102 | 3 | 250 | 750 | Efectivo | Norte | ✔ Válido |
| 3 | 02/05/2024 | Teclado | 103 | 1 | 450 | 450 | Tarjeta | Centro | ✔ Válido |
| 4 | 02/05/2024 | Monitor | 104 | 1 | 3,200 | 3,200 | Transferencia | Centro | ✔ Válido |
| 5 | 03/05/2024 | Impresora | 105 | 2 | 2,100 | 4,200 | Efectivo | Sur | ⚠ Corregido |

## 4. Normalización

La normalización es una técnica que transforma los valores numéricos para que se encuentren dentro de una escala común.
Esta técnica es ampliamente utilizada en minería de datos, inteligencia artificial y aprendizaje automático.

1. ANTES DE LA NORMALIZACIÓN (DATOS ORIGINALES)

| id_venta | fecha | producto | cantidad | precio_unitario ($) | ventas_total ($) | método_pago | sucursal |
|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | 1 | 1,000 | 1,000 | Tarjeta | Centro |
| 2 | 01/05/2024 | Mouse | 2 | 250 | 500 | Efectivo | Norte |
| 3 | 02/05/2024 | Teclado | 1 | 100 | 100 | Tarjeta | Centro |
| 4 | 02/05/2024 | Monitor | 1 | 750 | 750 | Transferencia | Centro |
| 5 | 03/05/2024 | Impresora | 1 | 1,500 | 1,500 | Efectivo | Sur |

3. DESPUÉS DE LA NORMALIZACIÓN (DATOS NORMALIZADOS ENTRE 0 Y 1)

| id_venta | fecha | producto | cantidad | precio_unitario ($) | ventas_total ($) (Original) | ventas_total_normalizado (0 a 1) | método_pago | sucursal |
|---|---|---|---|---|---|---|---|---|
| 1 | 01/05/2024 | Laptop | 1 | 1,000 | 1,000 | 0.64 | Tarjeta | Centro |
| 2 | 01/05/2024 | Mouse | 2 | 250 | 500 | 0.29 | Efectivo | Norte |
| 3 | 02/05/2024 | Teclado | 1 | 100 | 100 | 0.00 | Tarjeta | Centro |
| 4 | 02/05/2024 | Monitor | 1 | 750 | 750 | 0.46 | Transferencia | Centro |
| 5 | 03/05/2024 | Impresora | 1 | 1,500 | 1,500 | 1.00 | Efectivo | Sur |

# Actividad 4. Minería de Datos

## 1. Definición de minería de datos

Para mí, la minería de datos es como explorar un montón de información para encontrar cosas que a simple vista no se ven. O sea, es un proceso donde se analizan grandes cantidades de datos usando técnicas estadísticas, algoritmos y herramientas tecnológicas, todo con el fin de descubrir patrones, tendencias o comportamientos que estaban escondidos.

Es revisar y analizar datos para sacar información valiosa que nos ayude a tomar mejores decisiones o a resolver problemas dentro de una empresa.

## 2. Objetivos de la minería de datos

El objetivo principal es convertir todos esos datos que se acumulan en conocimiento útil que sirva para decidir mejor.

Los objetivos más importantes que le veo son:

- Descubrir patrones ocultos entre los datos.
- Identificar tendencias en el comportamiento de clientes, productos o procesos.
- Predecir lo que puede pasar a futuro con modelos predictivos.
- Detectar cosas raras o comportamientos fuera de lo normal.
- Mejorar la eficiencia de la empresa.
- Apoyar las decisiones estratégicas con datos reales.
- Generar conocimiento que le dé ventajas a la organización frente a otras.
- Optimizar procesos revisando lo que ha pasado antes.

La verdad, yo creo que la minería de datos es importante porque permite aprovechar toda la información que se genera en el día a día y transformarla en algo que de verdad sirva para mejorar los resultados.

## 3. Aplicaciones empresariales

La verdad es que la minería de datos se puede aplicar en un montón de sectores, porque en todos lados se genera información que se puede aprovechar. Estas son las áreas principales donde más se utiliza:

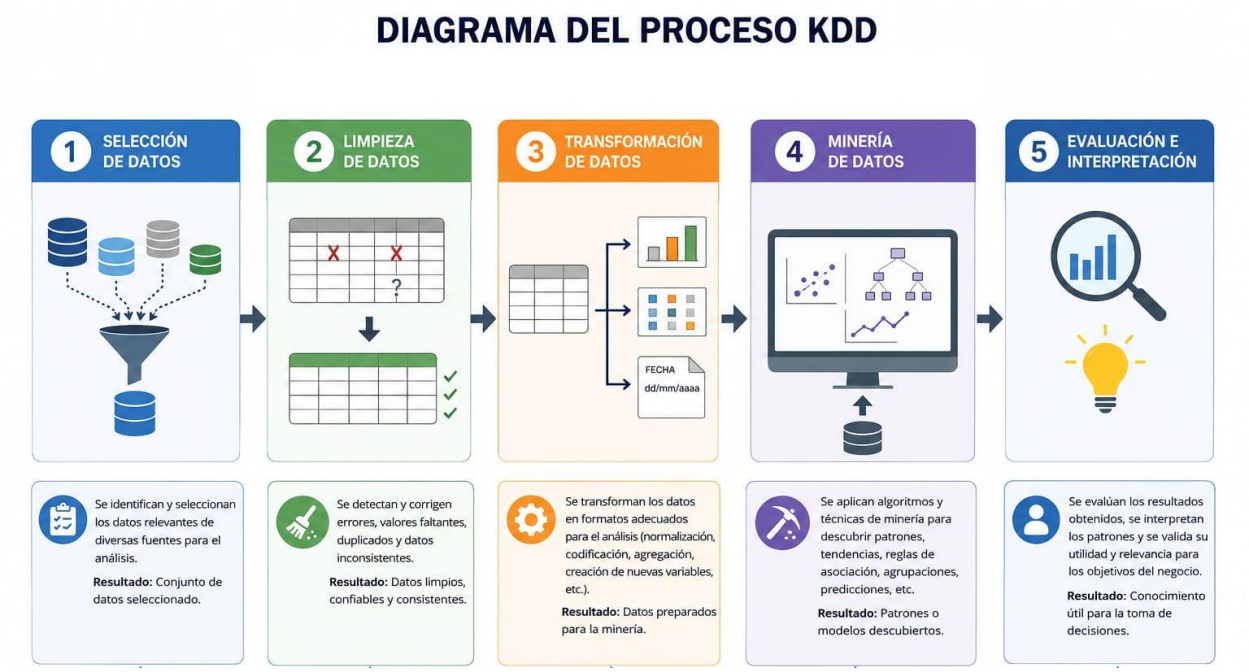
Comercio y ventas
Sirve para analizar los hábitos de compra, identificar qué productos se venden más y diseñar estrategias de marketing más efectivas. También se usa para segmentar clientes y crear promociones personalizadas.

Banca y finanzas
Aquí se ocupa mucho para evaluar riesgos, detectar actividades sospechosas, analizar inversiones y gestionar todo lo relacionado con créditos y finanzas de forma más segura.

Salud
En hospitales y centros médicos ayuda a analizar historiales clínicos, predecir enfermedades, identificar factores de riesgo y mejorar tanto los diagnósticos como los tratamientos. También sirve para una mejor gestión hospitalaria.

Marketing digital
En el mundo online se usa para analizar cómo se comportan los usuarios, conocer sus preferencias, segmentar mercados y mostrar publicidad o contenido personalizado según sus intereses.

## 4. Diagrama del Proceso KDD



# Parte II. Desarrollo Práctico

## Actividad 5. Implementación ETL con PySpark

### Extracción:

```
============================================================
PASO 1 - EXTRACCIÓN: DATAFRAME CREADO
============================================================

Estructura del DataFrame (info):
<class 'pandas.DataFrame'>
RangeIndex: 9 entries, 0 to 8
Data columns (total 5 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   Producto          9 non-null      str
 1   Categoria         9 non-null      str
 2   Ventas_Totales    7 non-null      float64
 3   Stock_Disponible  9 non-null      int64
 4   Precio_Unitario   9 non-null      float64
dtypes: float64(2), int64(1), str(2)
memory usage: 620.0 bytes

Primeras 5 filas:
    Producto Categoria  Ventas_Totales  Stock_Disponible  Precio_Unitario
0      Leche   Lácteos           120.0                10              1.2
1  Carne Res    Carnes            85.0                 8              8.5
2     Yogurt   Lácteos             NaN                20              1.5
3      Pollo    Carnes            60.0                12              5.8
4      Queso   Lácteos           150.0                 5              4.2

Dimensiones: 9 filas, 5 columnas
```

### Transformación

```
============================================================
PASO 2 - TRANSFORMACIÓN: LIMPIEZA Y ENRIQUECIMIENTO
============================================================

--- 2.1 Valores nulos ---
Registros con Ventas_Totales nulos: 2
      Producto  Ventas_Totales
2       Yogurt            NaN
6  Carne Cerdo            NaN
Valores nulos reemplazados por la mediana: 110.00

--- 2.2 Duplicados ---
Filas duplicadas antes: 0
Filas duplicadas después de eliminar: 0

--- DataFrame después de transformaciones ---
      Producto  Categoria  Ventas_Totales  Stock_Disponible  Precio_Unitario  Valor_Inventario
0       Leche    Lácteos           120.0                10              1.2              12.0
1   Carne Res     Carnes            85.0                 8              8.5              68.0
2      Yogurt    Lácteos           110.0                20              1.5              30.0
3       Pollo     Carnes            60.0                12              5.8              69.6
4       Queso    Lácteos           150.0                 5              4.2              21.0
5         Pan  Panadería           200.0                40              0.9              36.0
6  Carne Cerdo     Carnes           110.0                14              7.3             102.2
7  Mantequilla    Lácteos            90.0                 9              2.1              18.9
8       Crema    Lácteos           110.0                13              1.8              23.4
```

**Carga**

```
============================================================
PASO 3 - CARGA
============================================================
Datos guardados exitosamente en: inventario_limpio_ecomart.csv
```

inventario_limpio_ecomart.csv

```
Producto,Categoria,Ventas_Totales,Stock_Disponible,Precio_Unitario,Valor_Inventario
Leche,Lácteos,120.0,10,1.2,12.0
Carne Res,Carnes,85.0,8,8.5,68.0
Yogurt,Lácteos,110.0,20,1.5,30.0
Pollo,Carnes,60.0,12,5.8,69.6
Queso,Lácteos,150.0,5,4.2,21.0
Pan,Panadería,200.0,40,0.9,36.0
Carne Cerdo,Carnes,110.0,14,7.3,102.2
Mantequilla,Lácteos,90.0,9,2.1,18.900000000000002
Crema,Lácteos,110.0,13,1.8,23.400000000000002

```

# Parte III. Minería de Datos

## Actividad 6. Análisis Exploratorio

```
============================================================
ACTIVIDAD 6 - ANÁLISIS EXPLORATORIO
============================================================

1. Producto más caro: Carne Res (Precio: 8.50)
2. Producto con mayor inventario (stock): Pan (Stock: 40 unidades)
3. Producto de mayor valor económico en inventario: Carne Cerdo (Valor: 102.20)

--- Estadísticas adicionales ---
Resumen de variables numéricas:
       Ventas_Totales  Stock_Disponible  Precio_Unitario  Valor_Inventario
count        9.000000          9.000000         9.000000          9.000000
mean       115.000000         14.555556         3.700000         42.344444
std         40.466035         10.441637         2.867054         30.539528
min         60.000000          5.000000         0.900000         12.000000
25%         90.000000          9.000000         1.500000         21.000000
50%        110.000000         12.000000         2.100000         30.000000
75%        120.000000         14.000000         5.800000         68.000000
max        200.000000         40.000000         8.500000        102.200000

Valor total del inventario por categoría:
Categoria
Carnes       239.8
Lácteos      105.3
Panadería     36.0
Name: Valor_Inventario, dtype: float64
```

## Actividad 7. Predicción Simple

```
============================================================
ACTIVIDAD 7 - MODELO DE REGRESIÓN LINEAL
============================================================

Evaluación del modelo de regresión (Valor_Inventario ~ Ventas + Precio + Categoria):
  - Error Cuadrático Medio (MSE): 133.46
  - Coeficiente de Determinación (R2): 0.7786

Dataframe de comparación (valores reales vs predichos):
      Producto  Valor_Real  Valor_Predicho
0  Mantequilla        18.9        6.520207
1    Carne Res        68.0       78.661194

Dataframe completo con la predicción del modelo añadida:
      Producto  Valor_Inventario  Valor_Predicho_Modelo
0        Leche              12.0              24.038002
1    Carne Res              68.0              78.661194
2       Yogurt              30.0              18.198737
3        Pollo              69.6              76.870149
4        Queso              21.0              27.078186
5          Pan              36.0              36.000000

Dataframe completo con la predicción del modelo añadida:
      Producto  Valor_Inventario  Valor_Predicho_Modelo
0        Leche              12.0              24.038002
1    Carne Res              68.0              78.661194
2       Yogurt              30.0              18.198737
3        Pollo              69.6              76.870149
4        Queso              21.0              27.078186
5          Pan              36.0              36.000000
6  Carne Cerdo             102.2              94.929851
7  Mantequilla              18.9               6.520207
8        Crema              23.4              17.085075
```